

AquaPredict: Sistema inteligente baseado em MLP para previsão de nível em reservatórios de água

1st Alex Bruno Duarte

Universidade Federal Rural do Semi-Árido (UFERSA)

Pau dos Ferros - RN, Brasil

alex.duarte@alunos.ufersa.edu.br

2nd Carlos Henrique de Queiroz

Universidade Federal Rural do Semi-Árido (UFERSA)

Pau dos Ferros - RN, Brasil

carlos.queiroz53447@alunos.ufersa.edu.br

3rd José Veríssimo de Oliveira Queiroz

Universidade Federal Rural do Semi-Árido (UFERSA)

Pau dos Ferros - RN, Brasil

jose.queiroz58390@alunos.ufersa.edu.br

4th Thallys Araújo de Moraes

Universidade Federal Rural do Semi-Árido (UFERSA)

Pau dos Ferros - RN, Brasil

thallys.morais@alunos.ufersa.edu.br

Resumo—A gestão eficiente de recursos hídricos é um desafio crítico na infraestrutura moderna, exigindo soluções que evitem tanto o desabastecimento quanto o desperdício energético em sistemas de bombeamento. Este artigo apresenta o AquaPredict, um sistema preditivo baseado em inteligência artificial para o monitoramento e controle de reservatórios de água. A abordagem utiliza uma Rede Neural Perceptron Multicamadas (MLP) projetada para analisar séries temporais de alta granularidade. Utilizando o SOWEKI Water Demand Dataset, com leituras em intervalos de 15 minutos, o modelo é capaz de prever o nível hídrico com uma hora de antecedência. Os resultados experimentais demonstram uma alta precisão do modelo, alcançando um coeficiente de determinação (R^2) de 0,7880 e um Erro Médio Absoluto (MAE) de 0,84. Esta capacidade de previsão em curtíssimo prazo viabiliza a transição de sistemas de controle reativos para proativos, permitindo que a lógica de acionamento de bombas físicas, embarcada em microcontroladores na borda (edge computing), atue preventivamente para manter os níveis de segurança operacionais.

Index Terms—Gestão Hídrica, Inteligência Artificial, Internet das Coisas (IoT), Redes Neurais Artificiais, Séries Temporais.

I. INTRODUÇÃO

A otimização do uso da água e a eficiência energética são pilares fundamentais para o desenvolvimento sustentável em ambientes urbanos e industriais. Em sistemas de abastecimento e reaproveitamento hídrico, como a coleta de água de condensação de sistemas de climatização, o monitoramento do nível dos reservatórios dita o acionamento de bombas hidráulicas. Tradicionalmente, este controle é realizado de forma reativa, utilizando sensores de nível que ativam relés apenas quando um limite crítico de escassez ou transbordamento é atingido.

Embora funcionais, os sistemas reativos falham em antecipar picos de demanda, o que pode resultar em desgaste prematuro dos equipamentos devido a acionamentos intermitentes ou falhas no fornecimento. A ascensão da Internet das Coisas (IoT) em conjunto com técnicas de Aprendizado de Máquina (*Machine Learning*) oferece a oportunidade de transformar esses sistemas em infraestruturas inteligentes e proativas.

Este trabalho propõe o desenvolvimento do AquaPredict, uma arquitetura preditiva voltada para a gestão de reservatórios. O núcleo da inteligência do sistema é um modelo de Rede Neural Artificial do tipo *Multi-Layer Perceptron* (MLP). Diferente de abordagens baseadas em médias diárias, este estudo utiliza dados de alta granularidade — capturados em janelas de 15 minutos — extraídos do conjunto de dados *SOWEKI Water Demand*. O objetivo principal é fornecer uma previsão altamente acurada do nível da água com uma hora de antecedência, estabelecendo uma janela de tempo hábil para a tomada de decisão automatizada.

A integração desta rede neural com hardwares de processamento embarcado viabiliza a execução de lógicas de controle rigorosas, onde a bomba é acionada preventivamente com base na inclinação da curva de consumo futuro, e não apenas no estado presente.

O restante deste artigo está organizado da seguinte forma: a Seção II descreve a metodologia e o pré-processamento de dados. A Seção III detalha a arquitetura do modelo preditivo. A Seção IV apresenta os resultados experimentais e as métricas de avaliação. Por fim, a Seção V consolida as conclusões do trabalho.

II. METODOLOGIA E DADOS

A. Conjunto de Dados

Para o desenvolvimento desta etapa do trabalho, foi utilizado o conjunto de dados *SOWEKI Water Demand Dataset*, disponibilizado publicamente no repositório Zenodo. Este dataset contém medições contínuas com alta granularidade, registrando a demanda e os níveis hídricos em intervalos de 15 minutos. O objetivo principal da utilização desta base é permitir o desenvolvimento de modelos preditivos de curtíssimo prazo, capazes de antecipar quedas de nível.

Cabe destacar a contemporaneidade desta base de dados, publicada recentemente em abril de 2026. Durante a etapa de revisão bibliográfica desta pesquisa, não foram encontrados trabalhos prévios consolidados na literatura que utilizassem

este conjunto específico para o treinamento de modelos de Inteligência Artificial. A ausência de literaturas correlatas impossibilitou a comparação direta do desempenho do AquaPredict com modelos propostos por outros autores. Para contornar esta limitação e garantir o rigor científico da validação, optou-se pela implementação interna de um modelo de Regressão Linear Múltipla, o qual serviu como linha de base metodológica para atestar a necessidade e a superioridade de abordagens não-lineares.

B. Pré-processamento e Engenharia de Atributos

Para que a rede neural pudesse identificar padrões sazonais e tendências de consumo, os dados brutos passaram por uma etapa de engenharia de *features*. A partir da coluna temporal original, foram extraídas variáveis de sazonalidade: Hora, Minuto e Dia da Semana.

Para estabelecer o contexto histórico da série temporal, foram criadas quatro variáveis de atraso (*Lags*), correspondentes às leituras anteriores do sensor:

- *Lag1*: leitura de 15 minutos atrás;
- *Lag2*: leitura de 30 minutos atrás;
- *Lag3*: leitura de 45 minutos atrás;
- *Lag4*: leitura de 60 minutos atrás.

A variável alvo (*Target*) do modelo foi configurada para ser a leitura correspondente a 4 intervalos de tempo no futuro, o equivalente a prever o estado do reservatório com uma hora de antecedência.

III. ARQUITETURA DO MODELO

O sistema preditivo foi construído utilizando um Regressor *Multi-Layer Perceptron* (MLP). Os dados foram previamente padronizados utilizando *StandardScaler* para garantir que a variação de amplitude não enviesasse o treinamento. A divisão do conjunto de dados entre treino (80%) e teste (20%) foi realizada mantendo a ordenação cronológica rigorosa, evitando o vazamento de informações futuras para o passado (*data leakage*).

A arquitetura final da rede neural possui duas camadas ocultas, compostas por 64 e 32 neurônios, respectivamente. Esta estrutura em funil permite que a rede extraia interações complexas na primeira camada e comprima as informações mais relevantes na segunda. A função de ativação *Rectified Linear Unit* (ReLU) foi adotada devido à sua eficiência em lidar com picos agressivos de variação na série temporal. O limite máximo de iterações do otimizador estocástico foi estabelecido em 1000 épocas.

Para efeitos de validação científica da não-linearidade do problema, um modelo de Regressão Linear Múltipla foi treinado sob os mesmos dados para atuar como linha de base (*baseline*).

IV. RESULTADOS E DISCUSSÃO

A avaliação do modelo foi conduzida utilizando métricas padrão para problemas de regressão contínua: Erro Médio Absoluto (MAE), Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Determinação (R^2). Os resultados comparativos

entre a Rede Neural MLP e o modelo de Regressão Linear estão sintetizados na Tabela I.

Tabela I
COMPARATIVO DE DESEMPENHO DOS MODELOS

Modelo	MAE	RMSE	R^2
Regressão Linear	1,15	1,45	0,6394
MLP (ReLU)	0,84	1,11	0,7880

Conforme ilustrado na Tabela I, o modelo MLP obteve um desempenho substancialmente superior ao *baseline*. A capacidade da rede neural em capturar a variância dos dados alcançou quase 79% ($R^2 = 0,7880$), provando que a dinâmica de consumo hídrico obedece a padrões complexos e não-lineares, os quais o modelo linear falhou em mapear adequadamente ($R^2 = 0,6394$).




Figura 1. Comparativo entre o consumo real e o previsto pela rede neural em uma amostra do conjunto de teste.




Figura 2. Gráfico de dispersão ilustrando a correlação entre os valores reais e as previsões geradas pelo modelo MLP.

A análise visual das previsões corrobora os resultados numéricos obtidos. A Figura 1 ilustra o comportamento do modelo preditivo ao longo do tempo em uma janela de amostragem do conjunto de teste. É possível observar que a curva de

valores previstos acompanha com alta fidelidade as oscilações e tendências da curva de valores reais. O modelo demonstra notável capacidade de antecipar picos de alta demanda e vales de baixo consumo de forma sincronizada, um fator crítico para evitar o acionamento tardio ou desnecessário das bombas no sistema físico.

Complementarmente, a Figura 2 apresenta o gráfico de dispersão, evidenciando a correlação direta entre os valores medidos pelo sensor e os preditos pela Rede Neural. A concentração simétrica dos pontos ao longo de uma linha diagonal ascendente valida visualmente a precisão do algoritmo. Embora exista uma leve dispersão natural nas faixas de consumo mais atípicas (extremos do gráfico), a forte densidade e linearidade do agrupamento principal confirmam a robustez do preditor e refletem visualmente o alto coeficiente de determinação alcançado pela arquitetura.

A. Análise das Funções de Ativação

Para determinar a arquitetura matemática ideal da rede neural e garantir o máximo desempenho na captura de padrões sazonais, realizou-se um estudo comparativo empírico utilizando diferentes funções de ativação nas camadas ocultas. Os modelos foram treinados sob as mesmas condições de hiperparâmetros, alterando-se exclusivamente a função de ativação. Os resultados obtidos estão detalhados na Tabela II.

Tabela II
DESEMPENHO DO MLP COM DIFERENTES FUNÇÕES DE ATIVAÇÃO

Função de Ativação	MAE	RMSE	R^2
ReLU	0,84	1,11	0,7880
Tanh (Tangente Hiperbólica)	0,85	1,13	0,7798
Logística (Sigmoide)	0,86	1,15	0,7753
Identidade	1,15	1,46	0,6375

A análise da Tabela II revela que a função *Rectified Linear Unit* (ReLU) apresentou o melhor desempenho geral, com o menor índice de erro e a maior capacidade de explicação da variância (R^2), justificando sua adoção no modelo preditivo final. Cabe destacar o resultado da função Identidade que, por desativar o mapeamento não-linear da rede, obteve métricas virtualmente idênticas ao modelo de Regressão Linear estabelecido como *baseline*, reiterando a necessidade de funções complexas para a resolução deste problema hídrico.

O baixo índice de erro do modelo MLP, consolidado em um MAE de 0,84, viabiliza o uso deste algoritmo em sistemas físicos em tempo real. Com uma margem de erro sub-unitária, a lógica de controle programada no microcontrolador da bomba torna-se altamente confiável. O sistema foi programado para acionar preventivamente a bomba caso o *output* da IA indique que o nível atingirá o limite crítico de 3,0 na próxima hora, otimizando o gasto energético.

V. CONCLUSÃO

Este trabalho apresentou uma abordagem baseada em Redes Neurais Artificiais para a previsão de níveis hídricos em reservatórios com alta granularidade. Os resultados comprovam

que, para a automação de sistemas hídricos interligados, a utilização de séries temporais históricas em conjunto com arquiteturas de *Deep Learning* rasas (MLP) oferece uma vantagem preditiva significativa sobre os métodos puramente reativos ou lineares.

O R^2 de 0,7880 e a redução acentuada do Erro Médio Absoluto atestam a robustez do AquaPredict. O sistema mostra-se plenamente capaz de ser embarcado em infraestruturas IoT, provendo autonomia de decisão para hardwares de controle físico de bombas de forma preventiva, visando a sustentabilidade e a eficiência operacional.

AGRADECIMENTOS

Gostaria de expressar meus sinceros agradecimentos ao professor dr. Pedro Thiago Valério de Souza, pela orientação, dedicação e apoio ao longo do desenvolvimento deste trabalho. Sua experiência, disponibilidade e contribuições foram fundamentais para a realização desta pesquisa, proporcionando valiosos ensinamentos e incentivando o aprimoramento acadêmico e profissional dos autores.

REFERÊNCIAS

- [1] F. Sehmer, M. Hoffmann, N. Kloos, and R. Bergmann, "SOWEKI Water Demand Dataset," *Zenodo*, Apr. 2026.
- [2] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.